Универзитет у Београду - Електротехнички факултет
Катедра за сигнале и системе

Пројектни задатак из предмета

Неуралне мреже

Студенти
Ана Вуксановић
Наталија Димитријевић

Београд, март 2026. године

Садржај

1 Конволуциона неурална мрежа **1**
1.1 Увод 1
1.2 Одабир параметара модела 2
1.3 Резултати модела 3

1 Конволуциона неурална мрежа

1.1 Увод

Било је потребно пројектовати конволуциону неуралну мрежу (CNN) за класификацију слика на скупу података.
Изабрани скуп података има за циљ да олакша развој робусних и прецизних модела за предикцију погледа очију ради детекције непажљивих возача. Он је прикупљен помоћу напредног симулатора за праћење покрета очију, чиме је обезбеђен висококвалитетан скуп података о погледу очију за различите сценарије вожње.
Улазни подаци су фотографије типа *.jpg* и укупно их има 61073. Оне су подељене у 8 класа које показују правац и смер у којем су очи усмерене: *Bottom left*, *Bottom right*, *Bottom center*, *Top left*, *Top right*, *Top center*, *Middle right*, *Middle left*

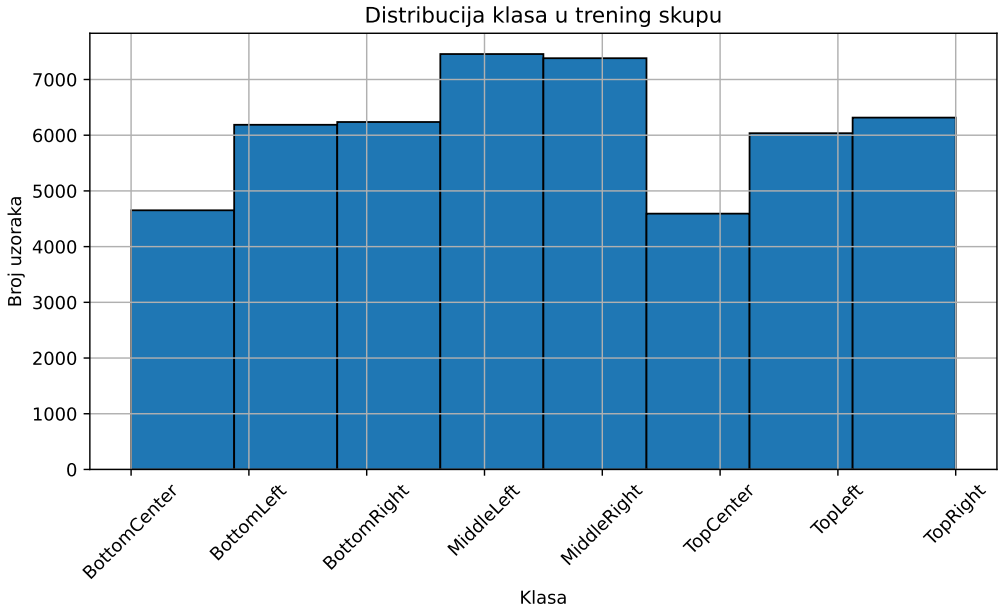

Слика 1.1: Хистограм расподеле узорака по класама

На хистограму се може приметити да су подаци из класа довољно добро расподељени, па није било потребе вршити балансирање скупова.
На следећој слици су приказани репрезентативни одбирци из сваке класе:

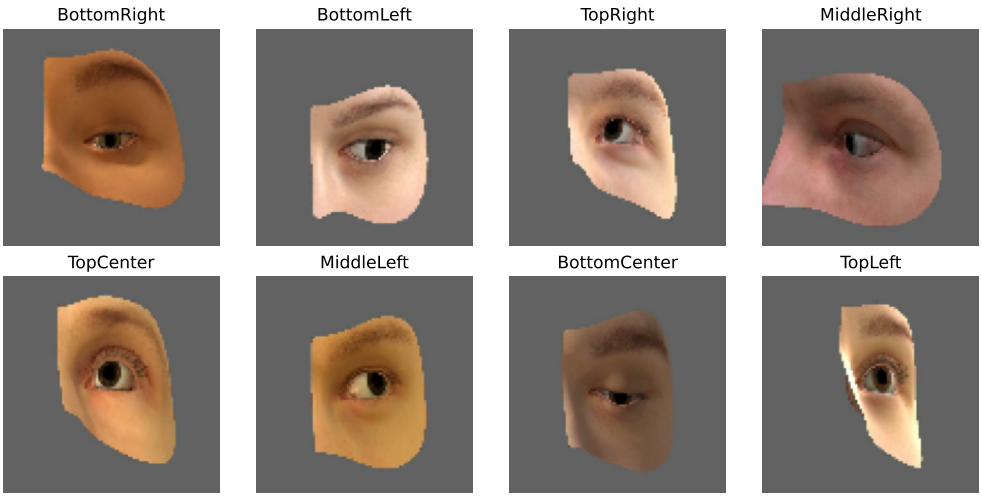

Слика 1.2: Репрезентативни одбирак из сваке класе

С обзиром на то да је оријентација очију на сликама од велике важности, стандардне функције аугментације попут ротације не би биле од помоћи, јер би могле променити смер гледања. Уместо тога, користе се функције које не мењају оријентацију, а ипак повећавају разноврсност података, као што су: насумично зумирање, насумичан контраст и насумично осветљење. Ове трансформације омогућавају моделу да буде отпорнији на различите услове осветљења и мале промене у величини, без нарушавања важних карактеристика слике.

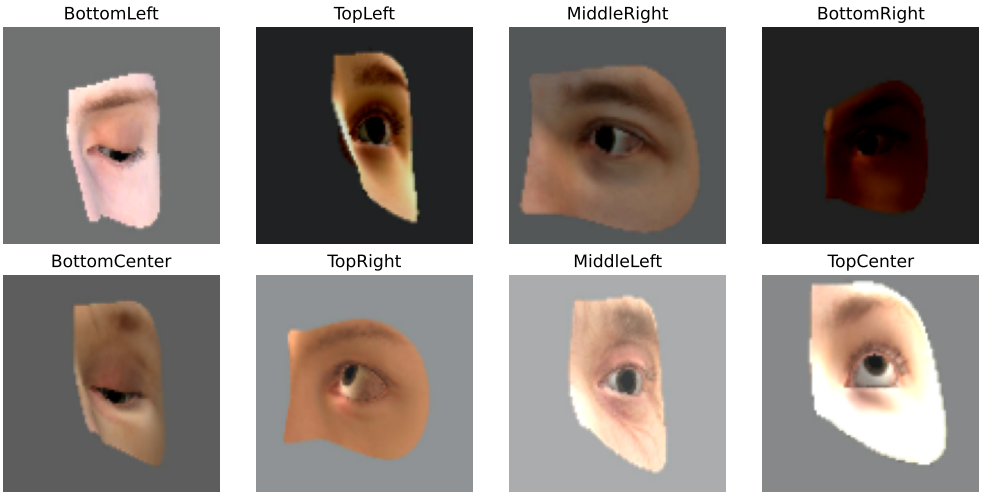

Слика 1.3: Репрезентативни аугментиран одбирак из сваке класе

1.2 Одабир параметара модела

У скривеним слојевима била је употребљена *ReLU* активациона функција, јер је њена предност у односу на пример на *sigmoid* и *tanh* та што не улази у сатурацију и немамо проблем нестајућег и експлодирајућег градијента. У излазном слоју употребљена је *Softmax* функција јер је она погодна за вишекласну класификацију и на излазу добијамо нешто што можемо протумачити као вероватноћу припадности одређеној класи. За оптимизацију одабран је метод *Adam* јер он комбинује две методе: *Momentum* и адаптивну стопу учења. Захваљујући томе обично брзо конвергира ка решењу.
При тренирању неуралне мреже може се јавити проблем преобучавања који представља појаву где се модел превише добро обучи на тренинг скупу, али показује лоше резултате на тест скупу, тј. на подацима које до тада није видео. Да би се ово спречило уводе се одређене методе за заштиту од преобучавања, а овде је коришћен метод раног заустављања (*EarlyStopping*).

Табела 1.1: Архитектура модела

Слој	**Број параметара**
Секвенцијални	0
Conv2D	448
Нормализација *batch*-а	64
MaxPooling2D	0
Conv2D	4,640
Нормализација *batch*-а	128
MaxPooling2D	0
Conv2D	18,496
Нормализација *batch*-а	256
MaxPooling2D	0
Dropout	0
Flatten	0
Dense	589,888
Dense	520

На табели 1.1 приказана је архитектура конволуционог неуронског модела. Модел је секвенцијални и састоји се од низа слојева који обрађују улазне слике.
Првих неколико слојева су конволуциони слојеви (*Conv2D*) који издвајају карактеристичне особине из улазних слика, праћени нормализацијом и *MaxPooling2D* која узима најкарактеристичнији пиксел из сваке слике.
Након тога, следи слој *Dropout* који спречава преобучавање мреже, а затим слој *Flatten* који претвара $3D$ излазе у $1D$ јер је то погодна димензија за обичну неуралну мрежу, *Dense*. *Dense* слојеви служе за коначно класификовање улазних слика у 8 различитих класа. Укупан број параметара ове мреже је 614440. Највећи део параметара потиче од последња два потпуно повезана слоја.

1.3 Резултати модела

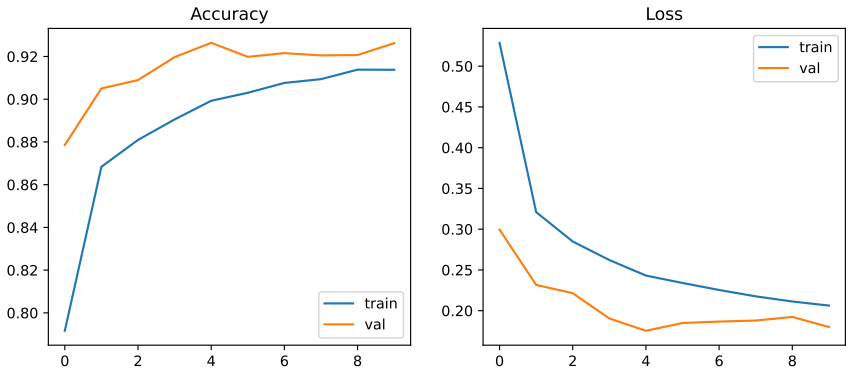

Слика 1.4: Промене перфорамнси током епоха тренирања

На слици 1.4 приказан је ток промене тачности (*accuracy*) и функције губитка (*loss*) на тренинг и валидационом скупу кроз епохе током процеса учења модела. Први график приказује промену тачности на тренинг и валидационом скупу, док други график приказује промену функције губитка за иста два скупа података.
Иако је максималан број епоха био подешен на тридесет, тренирање модела је завршено раније применом раног заустављања. Ова метода прекида процес тренирања када се перформансе модела на валидационом скупу више не побољшавају. У овом случају,

модел је заустављен након десете епохе, јер након пете епохе није дошло до побољшања тачности на валидационом скупу(пет је изабрано као параметар стрпљења).
Вредности метрика модела су следеће:

Метрика	**Вредност**
Тачност	0.9263959390862944
Прецизност	0.9269518257435593
Одзив	0.9263959390862944
$F1$ мера	0.9262863993606765

Табела 1.2: Резултати евалуације модела

Тачност је 0.9264, значи да је модел тачно класификовао 92.64% слика. Све метрике имају вредност око 0.93, што показује да модел постиже високу тачност и стабилне перформансе при класификацији података.

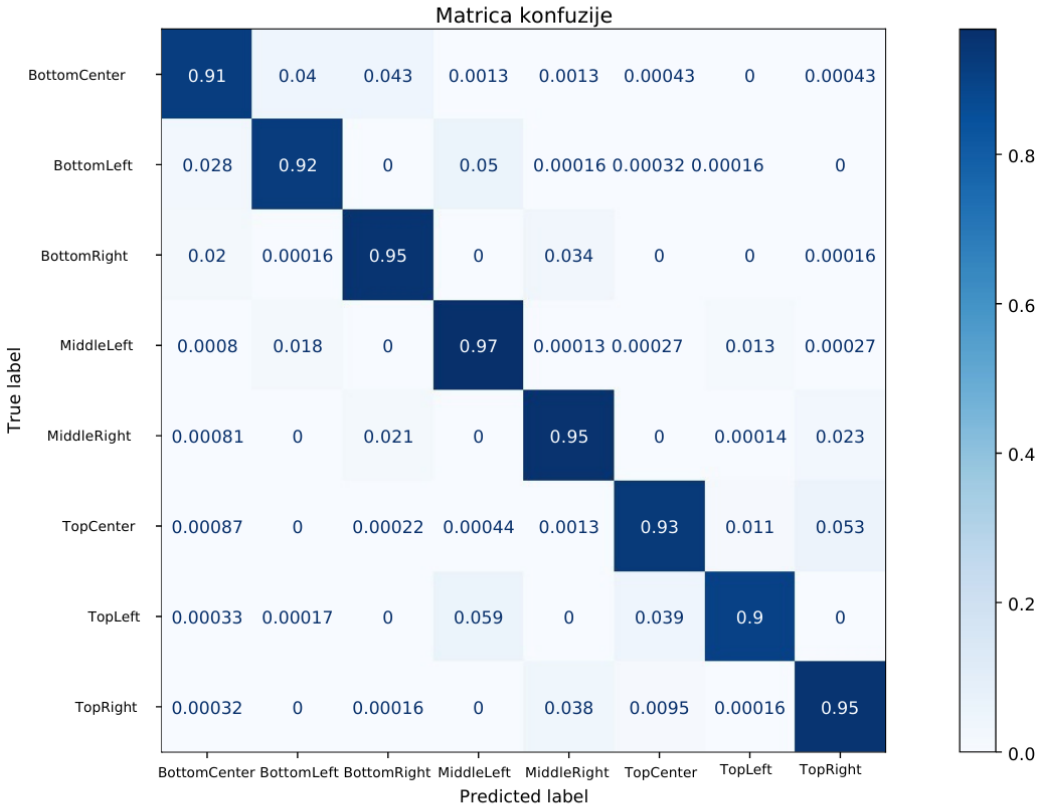

Слика 1.5: Матрица конфузије на тренинг скупу

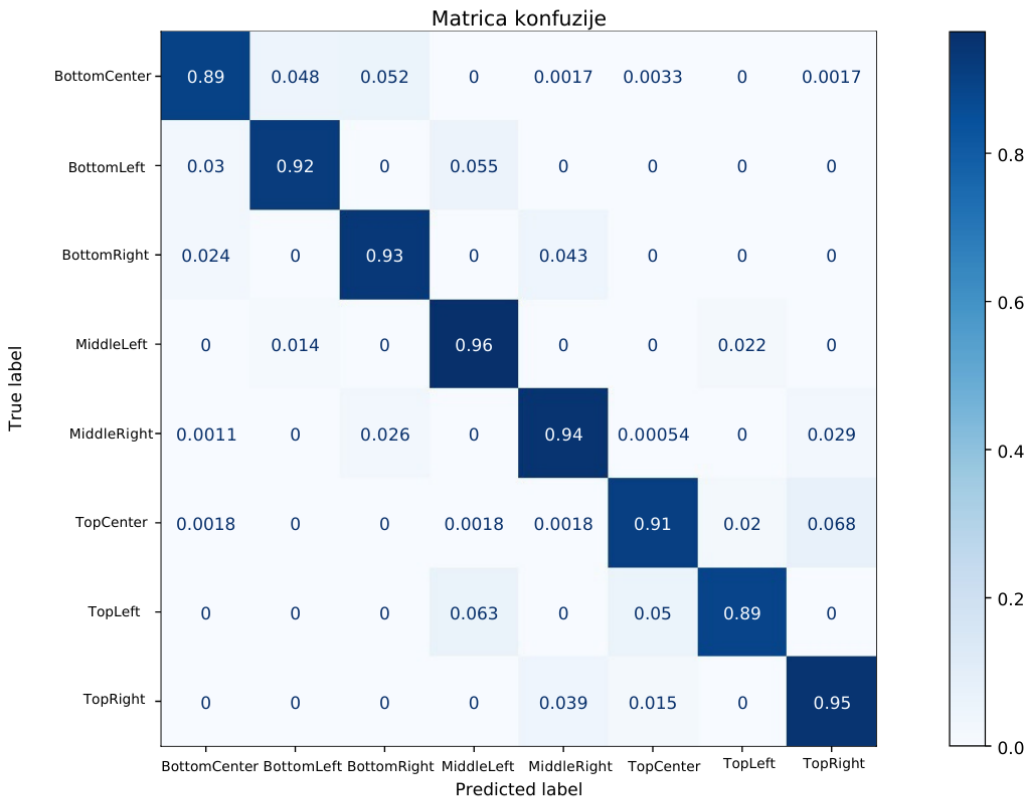

Слика 1.6: Матрица конфузије на тест скупу

У матрицама конфузије желимо да се на главној дијагонали налазе бројеви који су што ближе 1, јер то указује на то колико је одбирака добро класификовано за своју класу, а ван главне дијагонале се налазе лоше класификовани одбирци. Код нас обе конфузионе матрице имају сличне резултате и на главној дијагонали се налазе вредности између 0.89 и 0.97, што говори о високој тачности, као и о томе да није дошло до преобучавања.

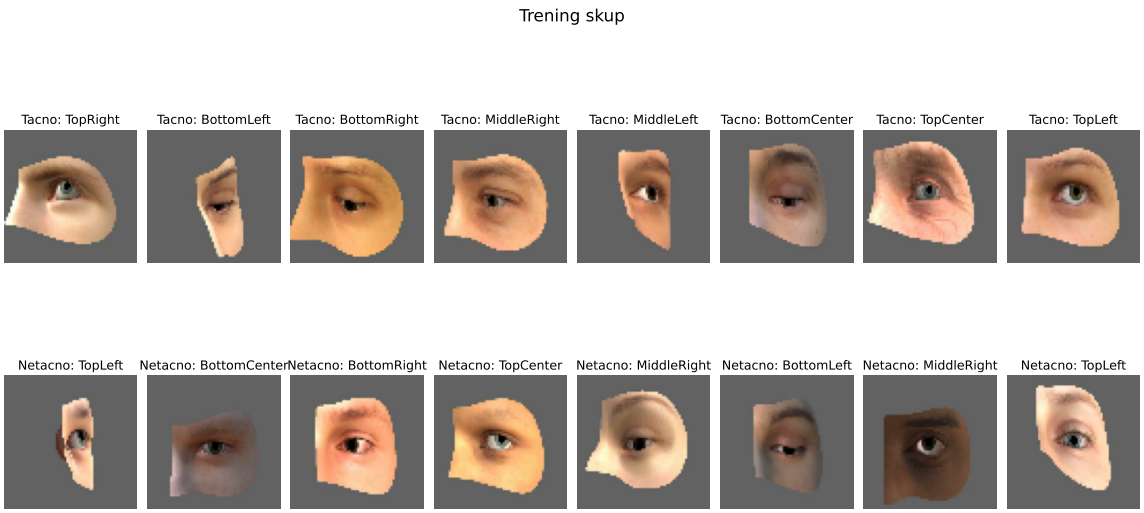

Слика 1.7: Добро и лоше класификовани одбирци из тренинг скупа

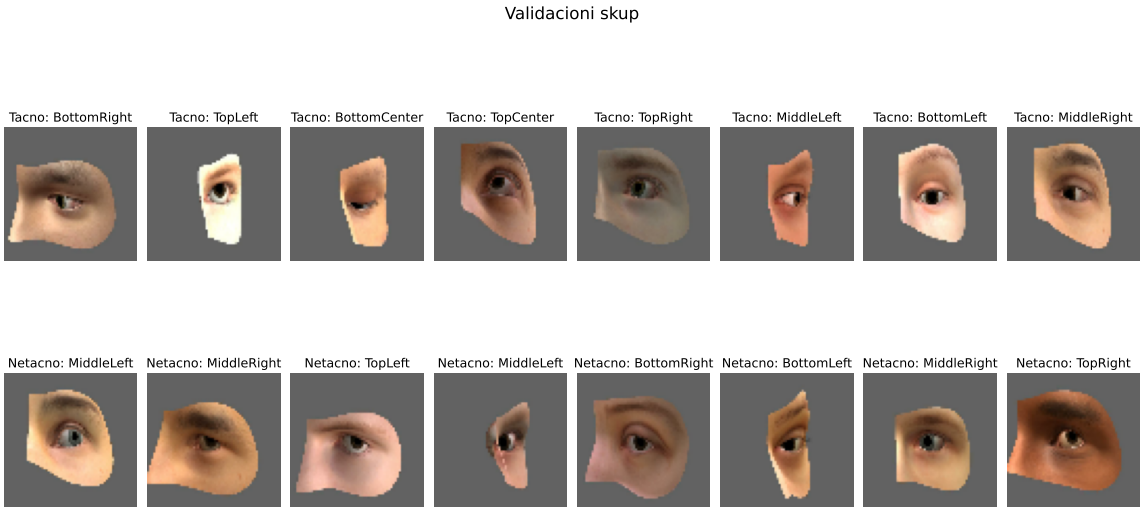

Слика 1.8: Добро и лоше класификовани одбирци из валидационог скупа

На слици 1.7 и 1.8 су приказани добро и лоше класификовани одбирци.